ClickHouse

Александр Смирнов

17.09.2020

Сценарии работы с данными

- Какие производятся запросы, как часто и в каком соотношении
- Сколько читается данных на запросы каждого вида - строк, столбцов, байт
- Как соотносятся чтения и обновления данных
- Какой рабочий размер данных и насколько локально он используется
- Какие требования к дублированию данных и логической целостности
- Требования к задержкам на выполнение и пропускной способности запросов каждого вида

Сценарии работы с данными (2)

- Не существует системы, одинаково хорошо подходящей под существенно различные сценарии работы
- Если система подходит под широкое множество сценариев работы, то при достаточно большой нагрузке, система будет справляться со всеми сценариями работы плохо, или справляться хорошо только с одним из сценариев работы

OLAP – интерактивная аналитическая обработка

- Подавляющее большинство запросов – на чтение
- Данные обновляются достаточно большими пачками (> 1000 строк), а не по одной строке, или не обновляются вообще
- Данные добавляются в БД, но не изменяются
- При чтении, вынимается достаточно большое количество строк из БД, но только небольшое подмножество столбцов
- Таблицы являются широкими, то есть, содержат большое количество столбцов
- При выполнении простых запросов, допустимы задержки в районе 50 мс
- Результат выполнения запроса существенно меньше исходных данных – то есть, данные фильтруются или агрегируются, результат выполнения помещается в оперативку на одном сервере

ClickHouse

- Распределенная аналитическая столбцовая (column-oriented) СУБД

Почему column-oriented?

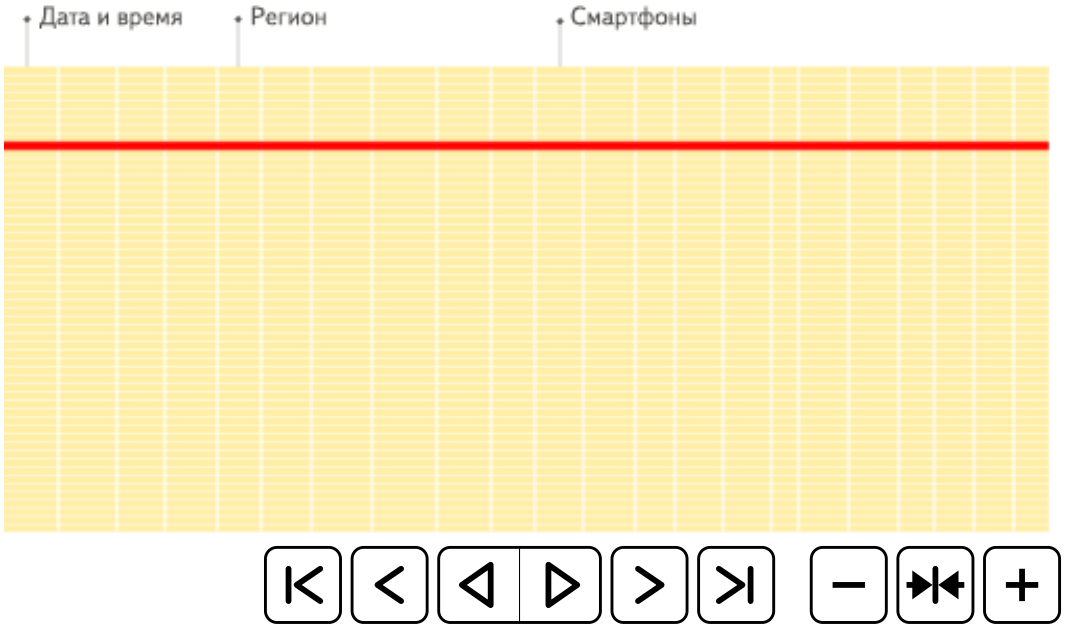

- В обычной row-oriented СУБД данные хранятся по строкам
- Хорошо подходит для обычных сценариев
  - изменить поле у пользователя
- Плохо подходит для задачи аналитики
  - пусть много столбцов, e.g. время, браузер, модель телефона
  - строки — события, e.g. просмотр страницы
  - нужен отчет по моделям телефона

Почему column-oriented? (2)

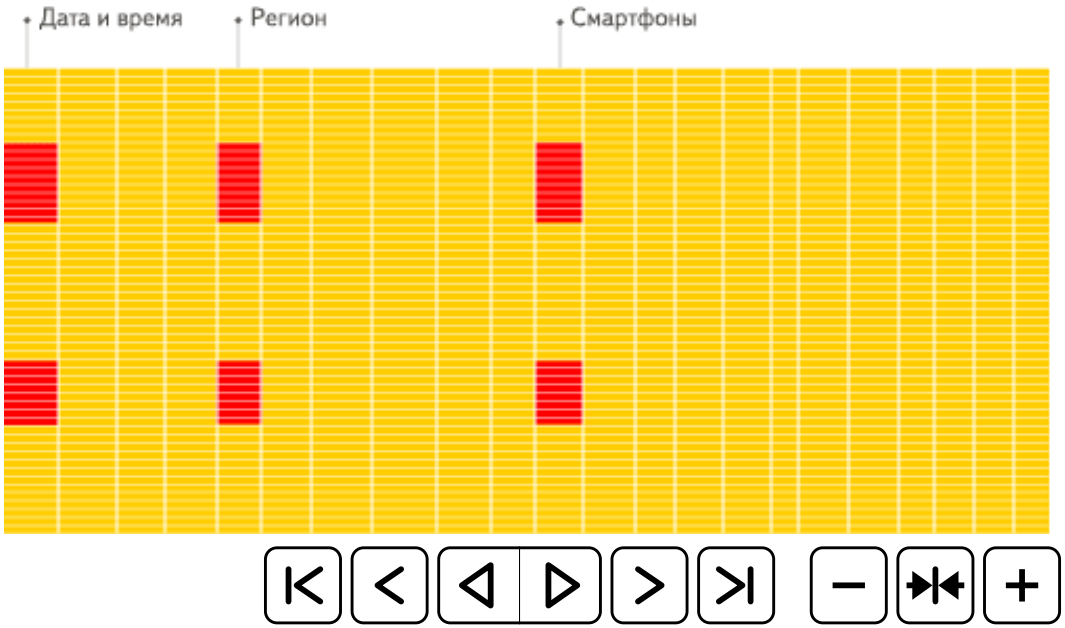

- Подходит система где данные хранятся по столбцам
- Данные, лежащие по столбцам, лучше сжимаются (однородные)

Преимущества

- Скорость
- Гибкость
  - доступны все данные, что хотим то и делаем с ними
- Масштабируемость
  - распределенное хранение данных
- Цена
  - цена разработчиков, не дорого

Недостатки

- Ограниченная поддержка JOIN
  - не больше одного подзапроса
- Нет UPDATE и DELETE
- Слабая совместимость со стандартом SQL

Как хранятся данные в таблицах

- ClickHouse – модульная система
- Разрабатывается снизу вверх
  - сначала работает на одной локальной машине
  - распределённая система собирается из множества локальных систем
- Поддерживает работу различных Storage Engines

Индекс БД

- Объект базы данных, создаваемый с целью повышения производительности поиска данных
- Часто реализуется B-деревом
  - хотим быстро доставать данные по идентификатору пользователя
  - отображение из значений ключа (e.g. идентификатор пользователя) в смещения на диске
  - B-деревья – дерево поиска с широкими node-ми

MySQL

- Запись данных
  - данные поступают по времени
  - записываются в конец
  - поступают перемешанно со всех сайтов
  - записи хранятся друг за другом последовательно
  - есть B-дерево, которое эти записи адресует по ключу
- Чтение данных
  - выбрать данные по одному сайту за период времени
  - ключ будет составным: идентификатор сайта, дата
  - по дереву вынимаем пачку смещений
  - выборка будет размазана по всем данным
- Достоинство: просто
- Недостаток: очень долго, данные расположены не оптимально для чтения

Log-structured merge-tree

- Заведем clustered index по сайтам, чтобы данные были физически упорядочены
- Вместо того, чтобы сразу записывать в файл, будем хранить новые записи в оперативной памяти
- Когда оперативная память заканчивается, сливаем записи с записями на диске
- Предоставляет быстрый доступ по индексу в условиях частых запросов на вставку

Векторная обработка запросов

- Проблема: как обрабатывать сложные запросы
  - сделать интерпретатор выражений
  - в аналитической СУБД нужно быстро фильтровать и агрегировать миллиарды строк
  - будет тормозить по CPU
- Решения
  - кодогенерация для компиляции запроса
    - компилируем машинный код и применяем для каждой строки
  - векторная обработка запроса
    - все операции пишутся не для отдельных значений, а для векторов
    - не только храним данные по столбцам, но и обрабатываем по столбцам

Benchmark

- Сравнение с другими СУБД
- Сравнение на разном железе

История

- Yandex.Metrika
- Данные по действиям пользователей на сайтах
  - как сохранить данные так, чтобы быстро строить отчеты
  - изначально предагрегировали данные, но пользователи хотели больше вариативности
- Пробовали разные столбцовые субд, не подошло

Распространение

- Open-source
- Есть своя небольшая ниша
- В России
  - Яндекс
  - Mail
  - СКБ Контур
  - Rambler
- За рубежом
  - Cloudfare
  - Wikimedia
  - Nvidia